Identification de patrons comportementaux associés à une progression rapide chez les joueurs d'échecs en ligne

Lemaire Romain
Département du génie des systèmes
École de Technologie supérieure
Montréal, Canada
romain.lemaire.1@ens.etsmtl.ca

Ratté Sylvie
Département du génie logiciel et des TI
École de Technologie supérieure
Montréal, Canada
Sylvie.Ratte@etsmtl.ca

***Résumé* — Comment progresser rapidement aux échecs ? Une réponse rapide serait de simplement jouer plus. Cependant, cet article tente de répondre à cette question en identifiant des schémas comportementaux associés à la progression des joueurs d'échecs en ligne. Les données utilisées proviennent de la plateforme d'échecs en ligne Lichess [1], dont l'historique complet des parties est disponible en ligne [2]. L'objectif a alors été d'explorer et d'exploiter qualitativement ces données dans l'optique de segmenter les joueurs selon leurs comportements. D'abord, nous avons sélectionné un ensemble de joueurs débutants ayant suffisamment joué dans une fenêtre temporelle commune. Ensuite, leurs parties ont été nettoyées et enrichies. Cela a permis de construire pour chaque joueur un ensemble de variables comportementales couvrant notamment le style, la fréquence et l'intensité de jeu. Enfin, le modèle de clustering (*K-means*) est parvenu à identifier des groupes de joueurs au moyen de ces variables. Les résultats suggèrent l'existence de comportements liés à la profondeur de jeu et à la résilience, qui influencent la dynamique de progression. Ces observations permettent de mieux comprendre les mécanismes d'apprentissage des échecs en ligne. De plus, elles offrent aux joueurs de potentielles pistes à explorer dans le but de progresser plus vite. La méthodologie utilisée pourrait également être une source d'inspiration dans ce domaine, encore peu exploré dans la littérature. Ce projet pourrait être prolongé en ajustant les critères de sélection des joueurs afin d'enrichir le jeu de données.**

I. Introduction et contexte

Le projet consiste en l'identification de schémas comportementaux associés à une progression rapide chez les joueurs d'échecs en ligne. Il s'agit d'effectuer du clustering afin de déceler d'éventuels profils-types de joueurs corrélés à une progression plus ou moins rapide. L'étude comportementale des joueurs est principalement portée sur les habitudes de jeu, et non pas sur l'analyse approfondie des parties.

Nous avons cherché à caractériser les comportements des joueurs indépendamment de leur volume de jeu. Il est évident qu'une quantité importante de parties favorise une meilleure progression. Afin de limiter ce biais, l'examen des joueurs se concentre sur des caractéristiques comportementales qualitatives et non quantitatives.

Ce travail repose sur l'analyse et l'exploration d'un grand ensemble de parties ayant été jouées sur la plateforme d'échecs en ligne, Lichess [1]. Le site donne l'accès à l'historique de l'ensemble des parties y ayant été jouées [2]. Pour chaque partie, il est renseigné un ensemble d'informations relatives aux joueurs, aux conditions de jeu, ainsi qu'à l'issue du match. Ces données nous servent à décrire comportementalement les joueurs par l'intermédiaire d'attributs et de statistiques. Cet ensemble de caractéristiques permet au modèle de clustering (***K-means***) de segmenter les joueurs en plusieurs ensembles. Ces groupes de joueurs ont été évalués et interprétés selon leur progression.

Sauf erreur de notre part, aucun travail identique à celui réalisé dans cet article n'a déjà été effectué. Nous pouvons cependant mentionner deux études comportant des similarités à ce projet.

Une première étude de Chess Digits [3] a analysé les patrons d'utilisation du temps lors des parties en ligne, en utilisant un clustering hiérarchique en vue d'identifier différents profils de rythme de jeu.

Une seconde étude [4] a été portée sur le regroupement de joueurs selon divers caractéristiques globales. L'analyse a recouru à l'algorithme ***K-means*** et à la réduction de dimension par ***PCA***.

Contrairement à notre papier, ces deux approches n'étudient pas explicitement le lien entre les profils comportementaux et la progression des joueurs. Elles ne permettent pas de déterminer si certains comportements sont associés à une amélioration accélérée du niveau de jeu. Le présent travail sépare la phase de clustering de l'évaluation de la performance, dans le but d'analyser en aval les relations entre comportements et progression. Plus précisément, le clustering est réalisé sans intégrer d'informations relatives à la progression absolue, et l'évaluation des clusters est effectuée a posteriori sur la base des progrès mesurés sur la période échantillonnée.

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

II. Objectifs

Ce travail accorde une importance particulière à la préparation et à la structuration des données. Il s'agit d'une étape essentielle pour l'analyse comportementale des joueurs.

L'objectif principal est d'identifier des schémas comportementaux associés à une progression rapide chez les joueurs d'échecs en ligne. Autrement dit, nous cherchons à répondre à la question suivante : « quels comportements sont associés à une progression rapide ? ». Plusieurs sous-objectifs découlent de ce but.

La première étape consiste à explorer, sélectionner, importer, nettoyer et enrichir les parties brutes. La finalité de cette étape est la caractérisation comportementale des joueurs à travers un ensemble d'attributs. Une quantification pertinente de la progression des joueurs est également attendue.

La seconde étape repose sur la séparation des joueurs par l'intermédiaire d'un algorithme de clustering appliqué exclusivement à des caractéristiques comportementales. La définition de métriques évaluant la pertinence du modèle est également requise. Un ensemble de configurations doit être testé et évalué afin de conserver quelques modèles pertinents pour l'analyse.

Enfin, les clusters obtenus sont analysés et interprétés à la lumière de la progression des joueurs. L'identification de comportements associés à une progression plus ou moins rapide est la finalité de cette étape.

III. Matériel

A. Données

Les données brutes sont l'ensemble des parties jouées sur la plateforme Lichess, dont chaque entrée correspond à une partie unique [2]. On y recense plusieurs centaines de millions de parties jouées par des millions de joueurs.

Les données étant trop volumineuses, un tri a été effectué dans la sélection des parties et des joueurs (section 4.B.). A l'issue de ce tri, 298 joueurs pour environ 150 000 parties ont constitué notre jeu de données. Ce volume de données permet d'obtenir une représentation suffisamment riche et variée des comportements de jeu.

Une partie se présente sous la forme de données textuelles, au format « Portable Game Notation » (***PGN***). Il s'agit d'un format standard de codage des parties d'échecs. Ce type de fichier est composé de deux parties : d'abord une liste d'en-têtes décrivant la partie et les joueurs, ensuite la liste des coups joués. Dans le cadre de cet article, l'étude est quasi-exclusivement portée sur la description des joueurs et de la partie. L'ensemble de ces informations n'étant pas utile, un tri de ces caractéristiques a été apporté.

La liste des attributs d'une partie brute est disponible dans l'annexe A. De manière non exhaustive, une partie est décrite temporellement par son début et sa fin, son mode de jeu, son format temporel, l'ouverture qui a été jouée et ses joueurs. Au sein d'une partie, chaque joueur est décrit par son identifiant, la couleur de ses pièces, et son score ***elo*** [5].

La quantification du niveau des joueurs repose sur le score ***elo***. Il s'agit d'un système d'évaluation permettant de chiffrer le niveau actuel d'un joueur. En somme, plus le score d'un joueur est élevé, plus ce dernier est virtuellement performant. À l'issue d'un match, le score ***elo*** du gagnant augmente alors que celui du perdant diminue.

B. Outils

Deux types d'outils ont été utilisés pour mener à bien ce projet.

D'une part, nous avons recouru à deux outils destinés à la sélection et à l'extraction des données. Le premier est l'outil de recherche de parties de Lichess [6]. Ce dernier a permis de sélectionner un premier pool de joueurs candidats. Le second est une API permettant d'importer les parties en appliquant des filtres [7]. L'intégralité de notre jeu de données a été téléchargé via cet outil.

D'autre part, le projet a été programmé exclusivement en ***Python***. Le traitement des données a été réalisé à l'aide des bibliothèques ***pandas*** et ***NumPy***. L'algorithme d'apprentissage machine a été implémenté via ***scikit-learn***. La visualisation des données et des résultats a été réalisée grâce à la bibliothèque ***Matplotlib***.

IV. Méthodologie

A. Pipeline global

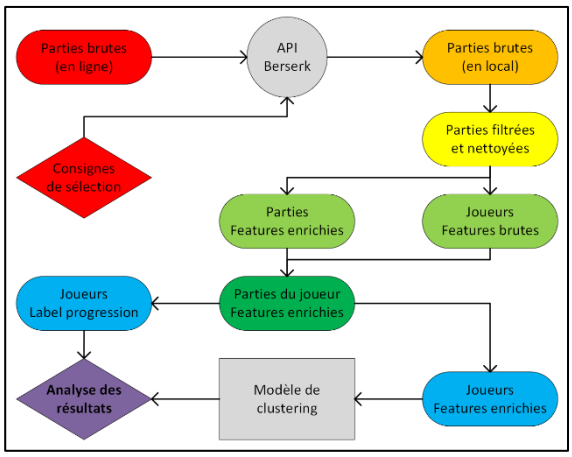

Figure 1 : Pipeline des données

L'image ci-dessus retrace l'ensemble du parcours des données.

D'abord, les données en ligne sont téléchargées via l'API en appliquant des critères de sélection. Les parties sont ensuite filtrées et prétraitées afin d'avoir un jeu de données structuré et exploitable.

Dans un second temps, les données sont scindées en deux : les joueurs et les parties. Les parties sont enrichies puis agrégées par joueur, permettant ainsi d'introduire une dimension temporelle.

A partir de ces données, deux types d'attributs sont construits afin de décrire le joueur. D'un côté, des caractéristiques comportementales sont établies et utilisées comme entrée du modèle de clustering. D'un autre côté, une métrique de progression est définie.

Enfin, les joueurs sont regroupés via l'algorithme de clustering. Les clusters obtenus sont finalement évalués et interprétés à l'aide de la métrique de progression.

B. Sélection des joueurs

Notre approche a consisté à sélectionner un ensemble de parties, sur base d'une sélection de joueurs répondant à certains critères. Cette sélection a été pensée afin de pallier deux problèmes. D'une part, un tri doit être appliqué car les données sont trop volumineuses pour être traitées dans leur intégralité. D'autre part, un ensemble de joueurs au profil similaire doit être sélectionné afin que la comparaison soit pertinente.

Plusieurs critères ont donc été établis quant à la sélection des joueurs. En résumé, nous avons décidé d'analyser le comportement de profils débutants dans le format ***Rapide***. Seuls les joueurs ayant joué un minimum de 200 parties, sur une fenêtre de 6 mois suivants leurs débuts, dans ce mode de jeu, ont été retenus. Ces critères de sélection permettent d'analyser des joueurs avec un volume de jeu suffisant, avec un niveau de jeu initial similaire, dans un mode de jeu représentatif de leur maîtrise du jeu. Le détail de ces critères de sélection est présenté en annexe B

C. Quantification de la progression

Nous avons choisi de quantifier la progression du joueur en calculant la pente de la régression linéaire de son score ***elo*** au cours de ses parties, indexées selon leur ordre chronologique.

$$\beta = \frac{\sum_{\{i=1\}}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{\{i=1\}}^{n}(x_i - \bar{x})^2} \qquad [1]$$

n correspond au nombre de parties du joueurs, x_i à la position de la partie i, $\bar{x}$ à la moyenne du nombre de parties ($= \frac{n+1}{2}$), y_i au score ***elo*** du joueur au début de la partie i,e et $\bar{y}$ à la moyenne du score ***elo*** du joueur sur l'ensemble des parties.

L'intérêt de cette métrique permet d'évaluer pertinemment la progression du joueur entre le début et la fin des parties échantillonnées. En effet, elle reflète la tendance globale de la progression, indépendamment du score ***elo*** initial et du temps écoulé entre les parties.

D. Feature engineering

1) Prétraitement et attributs d'une partie

Les parties brutes issues de l'API sont initialement structurées sous formes de données imbriquées. Le premier prétraitement consiste à les aplatir en représentation tabulaire exploitable.

Dans un second, certains attributs existants sont formatés et/ou normalisés, et d'autres attributs dérivés de ces derniers sont construits. Nous pouvons par exemple citer la variation de score ***elo*** respective de chaque joueur, le nombre de coups joués lors de la partie ou encore la catégorisation de l'ouverture (voir annexe C).

Cette étape permet d'obtenir un jeu de données structuré et enrichi, facilitant les futurs traitements.

2) Agrégation des parties d'un joueur

Cette étape consiste à réorganiser les données du point de vue des joueurs. Chaque partie est dans un premier temps dupliquée en deux observations distinctes, une pour chaque joueur. Cela permet d'associer à chaque joueur ses propres variables (résultat, son score ***elo***, sa couleur, …).

Les parties d'un joueur sont ensuite ordonnées chronologiquement. Cette structuration permet d'introduire une dimension temporelle et de construire des séries : l'évolution du score ***elo***, les séries de victoires et de défaites, les sessions de jeu (ensemble de parties jouées avec un intervalle de temps court) et l'agrégation des parties sur les échelles quotidienne et hebdomadaire. Ces séries temporelles sont détaillées dans l'annexe D.

Enfin, par l'intermédiaire des deux précédentes sous-étapes, un ensemble d'attributs a été établi pour décrire la partie. Ces caractéristiques sont recensées et détaillées dans l'annexe E.

3) Attributs d'un joueur

Cette étape consiste en la construction d'attributs pour le joueur, à partir des paramètres de l'historique de ses parties. L'objectif de cette phase est de décrire le comportement du joueur sur plusieurs dimensions comportementales.

Le style de jeu du joueur est décrit par des métriques telles que la profondeur moyenne de ses parties ou la diversité des ouvertures jouées.

Le comportement en fin de partie du joueur peut être caractérisé par le taux de parties qu'il a perdu par manque de temps ou par abandon.

Son rapport aux séries de victoires ou de défaites peut être estimé en quantifiant par exemple le temps d'attente entre les parties ou sa performance moyenne au sein d'une de ces séries.

Son rythme de jeu global peut être évalué en calculant la variabilité de son nombre de parties quotidien ou hebdomadaire.

La structure de ses sessions peut également refléter son comportement, en évaluant par exemple le nombre de parties moyen de ses sessions ou bien encore la variabilité du délai entre ses sessions.

En somme, un grand ensemble de métriques a été créé et catégorisé. Ces attributs sont les entrées du clustering. La pertinence de chacune de ces métriques repose sur une interprétation métier du domaine des échecs, visant à capturer les dimensions comportementales pertinentes pour l'analyse. L'ensemble des attributs est recensé et détaillé dans l'annexe F.

4) Nettoyage des attributs

Cette étape vise à sélectionner un sous-ensemble de variables pertinentes pour le clustering, sur base de leur distribution, variabilité et redondance au sein de notre jeu de données. Plusieurs traitements successifs ont été appliqués.

Dans un premier temps, chaque attribut a été analysé individuellement. L'analyse univariée consiste à évaluer le taux de valeurs manquantes, la variance, l'intervalle interquartile ainsi que l'asymétrie. Aucun attribut ne présentait de valeurs manquantes. Les paramètres à la variance trop faible ont été écartés, alors que ceux présentant une distribution très asymétrique ont été retenus pour une future transformation.

Dans un second temps, la corrélation entre chaque métrique et la métrique de progression a été calculée via les coefficients de Pearson et de Spearman. Les variables directement corrélées à la progression ont été écartées afin de ne pas introduire un biais dans la construction des clusters.

Ensuite, la corrélation de chaque paire de features a été évaluée, à nouveau avec les coefficients de Pearson et de Spearman. Lorsqu'une paire d'attributs présentait une importante corrélation, la métrique la moins pertinente, en termes d'interprétation métier, a été écartée afin de limiter la redondance.

Enfin, une log transformation a été appliquée au métriques présentant une importante asymétrie, afin de stabiliser leur distribution. De plus, une normalisation a été appliquée à l'ensemble des variables dans le but de les rendre comparables entre elles.

A l'issue de ce processus, le nombre de features a été significativement réduit, passant d'une trentaine à une dizaine de variables retenues.

E. Modélisation et évaluation

Cette étape consiste à regrouper les joueurs selon leurs caractéristiques comportementales. Il est important de rappeler que la métrique de progression n'est pas utilisée dans le processus de clustering, mais uniquement dans l'évaluation de la pertinence des groupes obtenus.

Le modèle de clustering retenu est l'algorithme K-means. Il a été retenu pour plusieurs raisons. Simple à mettre en œuvre, il permet une interprétation aisée des clusters. De plus, le temps d'exécution est rapide ce qui permet l'exploration de nombreuses configurations. Enfin, le nombre de groupe est contrôlable via l'hyperparamètre k, et les résultats sont reproductibles via une graine aléatoire.

L'évaluation des modèles est essentielle afin de conserver une quantité limitée de résultats pour l'analyse. Cela repose sur deux métriques complémentaires.

La première métrique a pour objectif de quantifier la capacité du clustering à discriminer des profils de progression. Cela a été calculé via l'écart-type pondéré des scores de progression entre les clusters. Concrètement, la dispersion des moyennes de progression des clusters est calculée, puis pondérée selon le nombre de joueurs respectif des clusters. Plus cette valeur est élevée, plus les groupes présentent des niveaux de progression différents, ce qui constitue l'objectif principal du projet.

La seconde métrique est le coefficient de silhouette. Ce paramètre mesure le pouvoir discriminant du clustering. Cette métrique évalue à la fois la compacité des clusters et leur séparation. Au plus la valeur du coefficient de silhouette est élevée, au plus le clustering est qualitatif.

Afin de sélectionner les meilleurs modèles, l'évaluation repose sur une fonction de score combinant ces deux métriques via une somme pondérée. D'abord normalisées, ces métriques ont ensuite été pondérées en adéquation avec l'objectif du projet. En effet, cette pondération vise à privilégier la métrique métier (70%) par rapport à la silhouette (30%). Dans le départage de certains modèles, d'autres métriques ont également été comparées telles que le déséquilibre de la taille des groupes et la taille du plus petit cluster.

Un protocole expérimental a été implémenté afin d'explorer une multitude de configurations. Plusieurs ensembles de features de différentes tailles ont été testés. Pour chacun d'eux, l'algorithme a été exécuté pour différentes valeurs de k comprises entre 3 et 5, et ce sur 20 initialisations aléatoires distinctes. Cette approche permet d'identifier les configurations les plus performantes et les plus robustes.

V. RÉSULTATS

A. Modèles retenus

En pratique, le protocole expérimental a été effectué en trois étapes.

Dans un premier temps, plusieurs sets de features variés et relativement conséquents ont été exécutés. Les résultats ont été médiocres, et ont laissé suggérer que le pouvoir discriminant des modèles est meilleur lorsque le nombre de features est limité.

Par conséquent, nous avons réalisé une deuxième série de tests en réduisant le nombre d'attributs par set (entre 3 et 7). Plus précisément, il a été testé l'ensemble des paires de catégories de features possibles. Toutefois, les résultats n'ont pas été concluants.

La dernière partie de ce processus a consisté à tester l'ensemble des combinaisons de 2 à 5 attributs. Cela a nécessité un temps de calcul bien supérieur aux précédentes étapes car des milliers de configurations ont été testés. Afin de sélectionner les meilleurs configurations parmi l'ensemble des résultats produits, des métriques autres que la fonction de score ont été comparées lors du filtrage (cf. section 4.E.). Une vingtaine de configurations a été retenue, mais seules trois d'entre-elles ont été analysées en raison de leur potentiel d'interprétabilité.

Le premier modèle, dit modèle temporel, repose sur des variables décrivant le rythme de jeu global. Il inclut le nombre de coups moyen des parties ainsi que plusieurs indicateurs de variabilité du rythme de jeu. Cette configuration permet de caractériser la régularité et l'intensité de l'activité des joueurs dans le temps.

Le second modèle a une approche minimale car il repose sur un nombre réduit de variables. Il inclut à nouveau le nombre de coups moyen des parties, le nombre de parties moyen d'une session de jeu et également la variabilité du délai entre les sessions.

Le dernier modèle retenu, dit modèle psychologique, partage certaines variables avec la configuration temporelle. Cette approche diffère car elle intègre en plus du nombre de coups moyen des parties et du rythme de jeu global, une variable décrivant le délai moyen entre les parties lorsque le joueur connaît dans une série de défaites. Cette métrique permet d'introduire la composante comportementale de résilience.

B. Analyse des clusters

Pour rappel, l'ensemble des attributs des joueurs est détaillé dans l'annexe F. Les modèles retenus ont été analysés via deux visualisations. La première est une carte thermique indiquant la prépondérance des attributs, standardisés, entre les clusters. La seconde visualisation est une boîte à moustaches représentant la tendance et la dispersion de la progression des différents clusters. Commençons par analyser le modèle temporel.

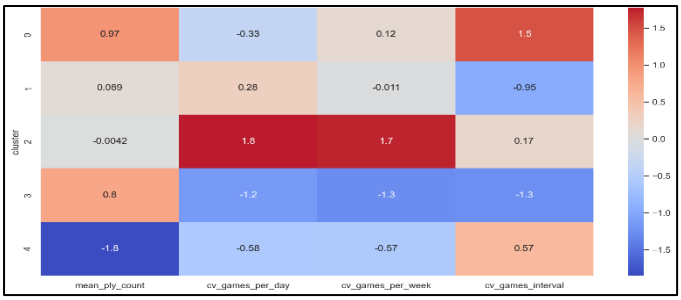

FIGURE 2 : CARTE THERMIQUE DU MODÈLE TEMPOREL

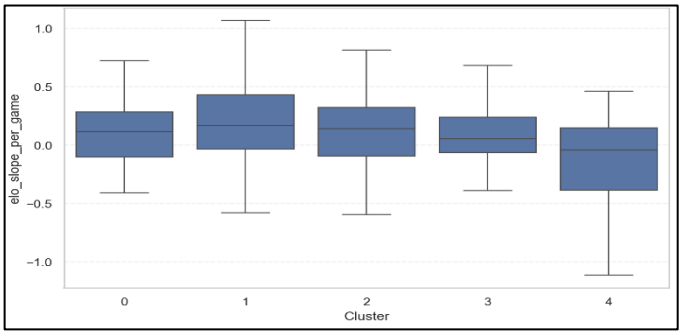

FIGURE 3 : BOÎTE À MOUSTACHE DU MODÈLE TEMPOREL

Les clusters de ce premier modèle mettent en évidence plusieurs profils de joueurs distincts. Un premier groupe se caractérise par des parties longues, un rythme de jeu irrégulier et une assez bonne progression. Le second cluster présente la meilleure progression et adopte un comportement très équilibré. Le troisième profil regroupe des joueurs très irréguliers avec une progression correcte. Le quatrième groupe comprend des joueurs très réguliers, aux parties relativement longues, et à une progression passable. Enfin, le dernier cluster est caractérisé par des parties courtes, un rythme de jeu relativement régulier, mais une mauvaise progression.

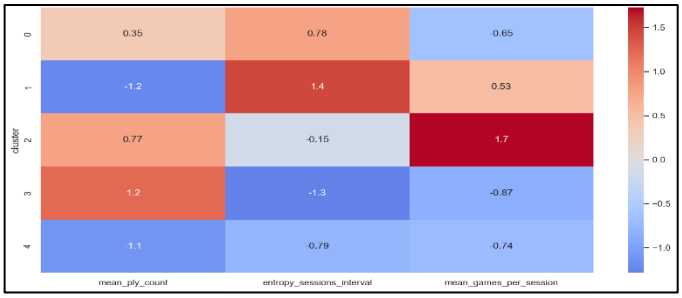

FIGURE 4 : CARTE THERMIQUE DU MODÈLE MINIMAL

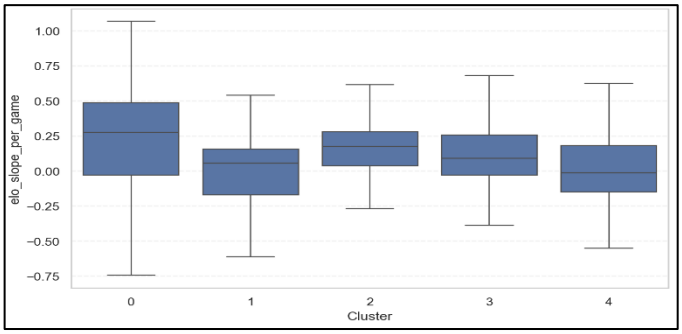

FIGURE 5 : BOÎTE À MOUSTACHES DU MODÈLE MINIMAL

Les clusters issus du modèle minimal mettent également en évidence plusieurs profils distincts. Le premier groupe se démarque par des sessions courtes et irrégulières, et par une bonne progression mais plus dispersée. Le second cluster regroupe des joueurs aux parties courtes, aux sessions de jeu irrégulières, et à une relativement mauvaise progression. A l'inverse, les joueurs du troisième groupe présentent des parties et des sessions de jeu longues, avec une assez bonne progression. Le quatrième cluster est caractérisé par des parties longues, et des sessions courtes et régulières. Ils présentent une progression intermédiaire. Enfin, les joueurs du dernier groupe jouent des parties courtes, ont des sessions courtes et irrégulières, et ont des progrès assez faibles.

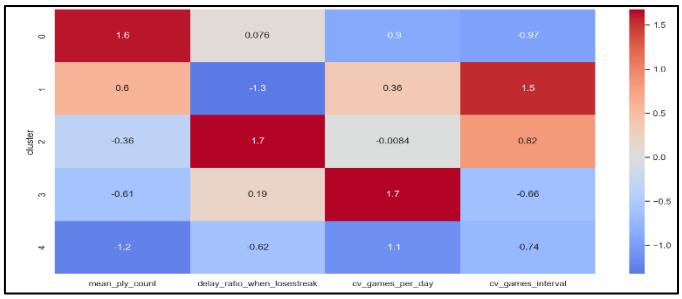

FIGURE 7 : CARTE THERMIQUE DU MODÈLE PSYCHOLOGIQUE

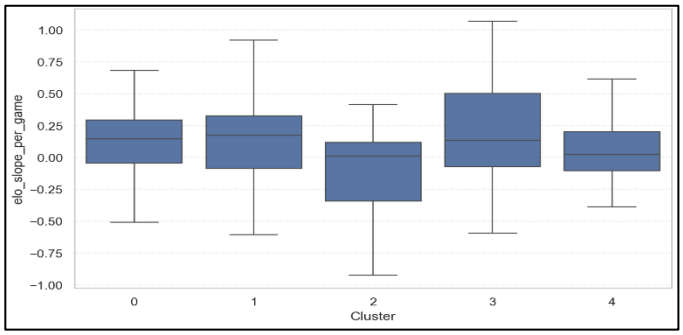

FIGURE 6 : BOÎTE À MOUSTACHES DU MODÈLE PSYCHOLOGIQUE

Ce dernier modèle intègre une nouvelle composante comportementale qui a permis de segmenter comportementalement les joueurs. Les joueurs du premier groupe sont réguliers, stables face à l'échec, disputent des parties longues et présentent une progression correcte. Le second cluster adopte un comportement irrégulier mais résilient. Ces joueurs ont tendance à enchaîner rapidement les parties lorsqu'ils accumulent les défaites. Ils présentent une bonne progression. En revanche, le troisième groupe a tendance à arrêter de jouer après les défaites, et est décrit par une mauvaise progression. Le quatrième cluster semble indifférent aux défaites, irrégulier dans son volume de jeu quotidien, et relativement performant. Enfin, le dernier groupe est caractérisé par des parties courtes, un rythme global régulier, et une progression moyenne.

C. Résultats globaux

Chaque modèle apporte une contribution dans l'identification des profils comportementaux performants. Les résultats du modèle temporel suggèrent que les joueurs disputant des parties longues performent davantage, et que la régularité n'est pas corrélée systématiquement à une meilleure performance. Le modèle minimal rejoint ce qui a été observé par le modèle temporel, mais confirme que la longueur et la régularité des sessions de jeu sont peu corrélées à la progression. Enfin, le modèle psychologique démontre que les joueurs persévérants dans l'échec progressent significativement plus que les joueurs abandonnant après les défaites.

Finalement, les résultats mettent en évidence deux profils de joueurs associés à une meilleure progression. D'une part, les joueurs adoptant un style de jeu plus stratégique en raison de la longueur de leurs parties, semblent progresser davantage. D'autre part, les joueurs résilients face à l'échec, n'abandonnant pas malgré les séries négatives, présentent également des meilleures performances. Enfin, ces deux constats apparaissent indépendamment du niveau de régularité du rythme de jeu.

VI. DISCUSSION

Les résultats obtenus pourraient être comparés à un travail existant portant également sur l'analyse comportementale des joueurs d'échecs en ligne. Le projet proposé par Singh [4] repose également sur des approches de clustering afin d'identifier des profils de joueurs. Cependant, la segmentation des joueurs se concentre principalement sur des caractéristiques globales, sans chercher à relier directement ces profils à une dynamique de progression. À l'inverse, notre approche vise à établir un lien entre les comportements observés et l'évolution du niveau de jeu.

Le choix méthodologique consistant à réaliser le clustering indépendamment de la progression constitue un atout majeur dans les résultats obtenus. En effet, cette dissociation permet d'éviter d'introduire un biais dans la construction des clusters, tout en capturant les potentielles interactions entre les variables comportementales. Contrairement à une analyse exclusive de la corrélation entre les variables et la progression, cette approche permet d'identifier des profils plus complexes.

Cependant, plusieurs limites doivent être soulignées. D'abord, le jeu de données reste restreint en termes de volume et de diversité, ce qui limite la généralisation des résultats. Ensuite, l'utilisation de K-means conditionne le clustering en favorisant notamment la forme sphérique des clusters et en étant relativement sensible aux conditions initiales. La reproduction des expériences avec d'autres modèles de clustering pourrait potentiellement présenter des résultats différents. Enfin, l'interprétation des clusters repose sur notre jugement, ce qui introduit une part de subjectivité. Bien que pertinente pour l'analyse, cette démarche pourrait être approfondie par des méthodes plus scientifiques et plus explicables. Ces éléments ouvrent des perspectives d'amélioration intéressantes.

VII. Conclusion

Ce projet s'est principalement concentré sur la préparation et la transformation des données, de leur extraction en ligne jusqu'à la création d'attributs comportementaux exploitables. L'objectif a été d'identifier des profils de joueurs d'échecs en ligne associés à une progression rapide, en séparant délibérément la phase de clustering de l'évaluation de la performance.

Les résultats obtenus répondent partiellement à la problématique. Plusieurs profils de joueurs ont été identifiés et corrélés à des progrès accrus. Les dimensions telles que la longueur des parties ou la résilience semblent impacter la dynamique de progression. Il faut cependant prendre ces résultats avec des pincettes, au regard des limites méthodologiques.

Nous pensons que la principale contribution de ce travail réside dans l'élaboration de la pipeline ayant permis de transformer les parties brutes en un ensemble de variables comportementales décrivant les joueurs. Les différents choix méthodologiques incluant la sélection des parties, le nettoyage des attributs, ainsi que l'interprétation métier des résultats, constituent également un apport dans le domaine. L'ensemble du programme et résultats sont accessibles sur notre dépôt GitHub [9].

Finalement, plusieurs pistes d'amélioration peuvent être envisagées. L'enrichissement du jeu de données, tant en termes de volume qu'en termes de diversité, permettrait de renforcer la robustesse des résultats. De plus, l'exploration d'algorithmes de clustering alternatifs, et de nouvelles approches méthodologiques d'interprétation des résultats, permettraient une meilleure généralisation et fiabilité des profils-types identifiés.

VIII. Utilisation néfaste

Les résultats de ce travail doivent être interprétés avec prudence au regard du cadre méthodologique et des limites de notre approche. Une utilisation néfaste de cet article pourrait être de tirer nos conclusions comme une vérité absolue.

Par exemple, nos résultats pourraient être repris de manière simplifiée, amplifiée voire déformée, par des créateurs de contenus dans l'optique d'appâter leur audience avec une soi-disant recette miracle pour progresser aux échecs. Une telle interprétation ignorerait la variabilité des joueurs selon leur niveau de jeu, les différences comportementales entre les modes de jeu, ainsi que les limites de notre étude.

IX. Références

[1] Lichess.org, "Lichess – Free Online Chess Server," [Online]. Available: https://lichess.org/. [Accessed: Apr. 16, 2026].

[2] Lichess.org, "Lichess Database – Open Database of Chess Games," [Online]. Available: https://database.lichess.org/. [Accessed: Apr. 16, 2026].

[3] Chess Digits, "Patterns of Time Usage During Games," [Online]. Available: https://web.chessdigits.com/articles/patterns-of-time-usage-during-games. [Accessed: Apr. 16, 2026].

[4] D. Singh, "Clustering Chess Expertise," GitHub repository, [Online]. Available: https://github.com/dhruvsingh14/clustering-chess-expertise. [Accessed: Apr. 16, 2026].

[5] Lichess.org, "Chess Rating Systems," [Online]. Available: https://lichess.org/page/rating-systems. [Accessed: Apr. 16, 2026].

[6] Lichess.org, "Advanced Game Search," [Online]. Available: https://lichess.org/games/search. [Accessed: Apr. 16, 2026].

[7] Lichess.org, "Berserk: Python Client for the Lichess API," GitHub repository, [Online]. Available: https://github.com/lichess-org/berserk. [Accessed: Apr. 16, 2026].

[8] ChessWorld.net, "Chess ECO Codes – Opening Guide," [Online]. Available: https://www.chessworld.net/chessclubs/openingguide/chess-eco-codes.asp. [Accessed: Apr. 16, 2026].

[9] R. Lemaire, "Clustering Chess Player Lichess," GitHub repository, [Online]. Available: https://github.com/rmnlmr-3011/clustering_chess_player_lichess. [Accessed: Apr. 16, 2026].

X. Annexes

A. *Annexe A – Liste des attributs d'une partie brute*

```
[Event "Rated Bullet tournament https://lichess.org/tournament/yc1WW2Ox"]
[Site "https://lichess.org/PpwPOZMq"]
[Date "2017.04.01"]
[Round "-"]
[White "Abbot"]
[Black "Costello"]
[Result "0-1"]
[UTCDate "2017.04.01"]
[UTCTime "11:32:01"]
[WhiteElo "2100"]
[BlackElo "2000"]
[WhiteRatingDiff "-4"]
[BlackRatingDiff "+1"]
[WhiteTitle "FM"]
[ECO "B30"]
[Opening "Sicilian Defense: Old Sicilian"]
[TimeControl "300+0"]
[Termination "Time forfeit"]

1. e4 { [%eval 0.17] [%clk 0:00:30] } 1... c5 { [%eval 0.19] [%clk 0:00:30] }
2. Nf3 { [%eval 0.25] [%clk 0:00:29] } 2... Nc6 { [%eval 0.33] [%clk 0:00:30]
3. Bc4 { [%eval -0.13] [%clk 0:00:28] } 3... e6 { [%eval -0.04] [%clk 0:00:30
4. c3 { [%eval -0.4] [%clk 0:00:27] } 4... b5? { [%eval 1.18] [%clk 0:00:30]
5. Bb3?! { [%eval 0.21] [%clk 0:00:26] } 5... c4 { [%eval 0.32] [%clk 0:00:29
6. Bc2 { [%eval 0.2] [%clk 0:00:25] } 6... a5 { [%eval 0.6] [%clk 0:00:29] }
```

Figure 8 : Exemple de partie brute

Voici une brève description de chaque champ :

- « Event » : mode de jeu et contexte de la partie
- « Site » : url de la partie
- « Date » : date de la partie
- « Round » : champ décrivant l'historique des rencontres des 2 joueurs
- « White » et « Black » : identifiants des joueurs selon la couleur des pièces jouées
- « Result » : issue du match
- « UTCDate » et « UTCTime » : date et heure de la partie
- « WhiteElo » et « BlackElo » : scores Elo des joueurs selon la couleur des pièces jouées
- « WhiteRatingDiff » et « BlackRatingDiff » : différence relative du score Elo des deux joueurs, selon la couleur des pièces jouées

- « ECO » : catégorie de l'ouverture jouée
- « Opening » : intitulé de l'ouverture jouée
- « TimeControl » : contrôle du temps de la partie (paramètre de jeu)
- « Termination » : cause de fin de la partie
- Enfin, le déroulé de la partie

B. Annexe B – Critères de sélection des joueurs

Un ensemble de 5 critères ont été établis pour sélectionner les joueurs de notre jeu de données.

D'abord, nous avons limité la portée de cette étude à un unique mode de jeu : le format ***Rapide***. Bien que les modes de jeu ***Bullet*** et ***Blitz*** soient plus joués, ce sont des formats très rapides qui induisent beaucoup de variables aléatoires et représentent mal le niveau stratégique du joueur. Le mode de jeu ***Classique*** représente probablement le mieux la maîtrise de jeu du joueur mais n'est pas assez joué. Par conséquent, notre choix s'est porté sur le mode ***Rapide***.

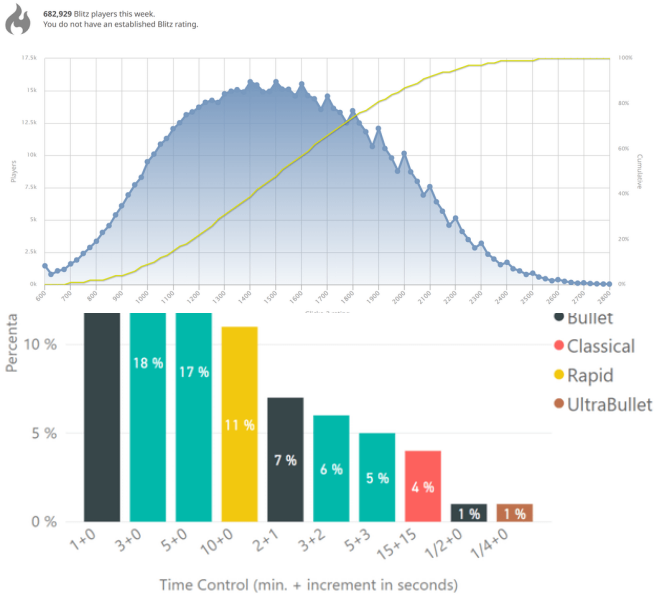

FIGURE 9 : DISTRIBUTION DU NOMBRE DE PARTIES JOUÉES SUR LICHESS SELON LE MODE DE JEU

Le second critère porte sur la période de sélection des parties Nous avons décidé de sélectionner uniquement des parties jouées en 2024 ou ultérieurement. Bien que les règles des échecs n'aient pas été réinventées, le jeu a connu un essor ces dernières années. Il y a donc probablement eu des tendances qui ont changé le comportement des joueurs (certaines ouvertures plus jouées, fréquence de jeu altérée…).

Pour un joueur, les parties sélectionnées appartiennent exclusivement à une fenêtre d'observation de 6 mois succédant sa première partie dans le format ***Rapide***. D'une part, se limiter à une fenêtre de 6 mois permet de comparer les joueurs dans des conditions temporelles similaires, de rendre pertinente une analyse temporelle (quotidienne et hebdomadaire) des joueurs, et de comporter suffisamment de parties par joueur. D'autre part, ne considérer que les premières parties du joueur permet d'analyser son évolution lors de ses débuts, ce qui s'aligne à notre volonté d'étudier des profils débutants.

Seuls les joueurs disposant d'un nombre de parties suffisant dans la fenêtre de 6 mois sont conservés. La première raison est qu'un nombre de parties trop faible risquerait de bruiter les métriques comportementales. La seconde raison est l'impertinence de comparer des joueurs avec un volume de jeu trop déséquilibré. Nous avons fixé empiriquement ce nombre à 200, car ce seuil permet d'assurer un compromis entre robustesse statistique des métriques, et taille de l'échantillon des joueurs.

Les 20 premières parties du joueur sont utilisées pour évaluer le niveau initial du joueur, et écartées de l'analyse. Les premières parties influencent grandement la variation du score ***elo***, car elles permettent au joueur de converger rapidement vers son vrai niveau de jeu. A l'issue de 20 parties, nous considérons empiriquement que suffisamment de parties ont été jouées pour écarter les joueurs débutants, des joueurs plus avancés. Ainsi, seuls les joueurs ayant un score elo compris entre 1000 et 1400 sont retenus.

C. Annexe C – Catégorisation des ouvertures

Les catégories d'ouvertures sont identifiées à l'aide du code ECO [8]. Chaque type d'ouverture est représenté selon une combinaison d'une lettre (A à E) et d'un nombre. Il s'agit d'une hiérarchie intermédiaire entre le nom complet de l'ouverture, et

FIGURE 10 : DISTRIBUTION DU SCORE ELO DES JOUEURS SUR LICHESS

la catégorie générale de cette dernière. C'est en partie sur base de cette structure que nous avons décidé de catégoriser les ouvertures, afin de refléter au mieux les habitudes des joueurs sur ce plan.

Plus précisément, nous avons décidé d'agréger des ensembles de codes ECO aux propriétés similaires afin de réduire le nombre total de catégories. Ce choix permet de conserver des catégories plus robustes et interprétables. Ces combinaisons ont été définies empiriquement, et sur base de la littérature dans le domaine [8].

Par exemple, les ouvertures au code ECO compris dans l'intervalle C0 à C19 font partie de la catégorie « Défense Française »

D. Annexe D – Séries temporelles

Afin de capturer la dynamique de jeu des joueurs, plusieurs séries temporelles ont été construites à partir des données ordonnées chronologiquement.

Les deux premières série correspondent à la série de victoires (winstreak) ou de défaites (losestreak) du joueur. Après chaque partie, un score de steak est mis à jour : il est incrémenté en cas de victoire consécutive, décrémenté en cas de défaite

consécutive, et réinitialisé à zéro en cas de changement de résultat ou de match nul. Une valeur positive correspond ainsi à une série de victoires, tandis qu'une valeur négative correspond à une série de défaites.

Les parties sont également regroupées en sessions de jeu, définies comme des séquences de parties séparées par des intervalles de temps court. Une nouvelle session est créée lorsque le délai entre deux parties consécutives excède 60 minutes.

Enfin, les parties sont également agrégées à l'échelle journalière et hebdomadaire afin de capturer le comportement du joueur sur des périodes plus ou moins courtes.

E. Annexe E – Attributs des parties

Les attributs des parties décrivent à la fois le contexte de jeu, la performance du joueur et sa dynamique temporelle. Les features sont calculées à l'échelle de la partie, mais certaines intègrent une dimension temporelle en exploitant l'historique des parties du joueur. Voici l'ensemble de ces attributs :

- **player** : identifiant du joueur
- **color_player** : couleur jouée (blanc / noir)
- **result_player** : résultat de la partie (1 = victoire, 0.5 = nul, 0 = défaite)
- **elo_player_before** : score Elo avant la partie
- **elo_player_after** : score Elo après la partie
- **elo_diff_player** : variation d'Elo entre avant et après la partie
- **termination_type** : type de fin de partie (normal, abandon, perte au temps)
- **has_increment** : présence d'un incrément de temps
- **opening_family** : famille d'ouverture (niveau agrégé, voir annexe C)
- **datetime_utc** : date et heure de la partie
- **weekday_utc** : jour de la semaine
- **game_id** : identifiant unique de la partie
- **ply_count** : nombre de demi-coups
- **index** : position de la partie dans l'historique du joueur
- **delay_previous_game** : différence de temps entre la partie courante et la précédente
- **streak_after** : longueur de la série après la partie
- **streak_before** : longueur de la série avant la partie
- **session_id** : identifiant de session
- **session_position** : position de la partie dans la session courante
- **session_size** : nombre de parties dans la session
- **session_score** : performance moyenne sur la session
- **session_delay** : temps entre deux sessions
- **session_discrete_delay** *(catégoriel)* :
    - A : < 6h
    - B : < 24h
    - C : < 3 jours
    - D : < 7 jours
    - E : ≥ 7 jours
- **day_n_games** : nombre de parties dans la journée
- **day_score** : score moyen de la journée
- **day_position** : position de la partie dans la journée
- **week_n_games** : nombre de parties dans la semaine
- **week_score** : score moyen hebdomadaire
- **week_position** : position dans la semaine

F. Annexe F – Attributs des joueurs

Les attributs des joueurs sont obtenus par agrégation des parties d'un joueur sur la période d'observation. Elles visent à capturer différentes dimensions du comportement de jeu. En voici la liste exhaustive, triée par catégorie :

Plusieurs attributs décrivent le style de jeu du joueur :

- **mean_ply_count** : nombre moyen de demi-coups par partie (élevé : joueur stratégique ; faible : joueur tactique)
- **main_opening_white** : ouverture la plus jouée avec les blancs (permet d'identifier des préférences stratégiques)
- **main_opening_black** : ouverture la plus jouée avec les noirs (permet d'identifier des préférences stratégiques)
- **opening_diversity** : entropie des ouvertures jouées (élevé : joueur varié ; faible : joueur spécialisé)
- **opening_concentration** : proportion de l'ouverture principale (élevé : joueur très spécialisé)

Quelques attributs décrivent le comportement du joueur en fin de partie :

- **abandon_rate** : taux d'abandon (élevé : tendance à abandonner rapidement)

- **time_loss_rate** : taux de défaites au temps (élevé : mauvaise gestion du temps)
- **draw_ratio** : proportion de matchs nuls

Certains attributs interprètent le rapport du joueur aux séries de victoires ou de défaites :

- **score_when_winstreak** : performance moyenne en série de victoires (élevé : effet de confiance)
- **score_when_losestreak** : performance moyenne en série de défaites (élevé : résilience ; faible : tilt)
- **streak_resilience_bias** : impact global des streaks sur la performance (synthèse des comportements face aux séries)
- **abandon_rate_when_losestreak** : taux d'abandon en série de défaites (élevé : faible résilience)
- **time_loss_rate_when_losestreak** : pertes au temps en série de défaites
- **delay_ratio_when_winstreak** : variation du délai entre parties en winstreak (<1 : enchaînement rapide ; >1 : ralentissement)
- **delay_ratio_when_losestreak** : variation du délai en losestreak

Certaines features décrivent le rythme de jeu global du joueur :

- **cv_games_interval** : coefficient de variation des intervalles entre parties (élevé : rythme irrégulier)
- **cv_games_per_day** : coefficient de variation du nombre de parties par jour (élevé : rythme irrégulier)
- **cv_games_per_week** : coefficient de variation du nombre de parties hebdomadaire (élevé : rythme irrégulier)

D'autres features décrivent les sessions de jeu du joueur :

- **cv_sessions_interval** : coefficient de variation du temps entre sessions (régularité des habitudes de jeu)
- **entropy_sessions_interval** : entropie des intervalles entre sessions (distingue régularité vs comportement chaotique)
- **mean_games_per_session** : nombre moyen de parties par session
- **cv_games_per_session** : coefficient de variation du nombre de parties par session

Le contexte de jeu peut également être décrit par ces attributs :

- **increment_game_ratio** : proportion de parties avec incrément (caractérise le type de parties jouées)
- **weekday_bias** : différence de performance semaine vs week-end (> 0 : meilleur en semaine)
- **color_bias** : différence de performance blanc vs noir (>0 : meilleur avec les blancs)

Quelques métriques finalement écartées car trop corrélées à la progression, décrivent la dynamique de performance du joueur :

- **session_length_performance_slope** : impact de la longueur de session sur la performance (> 0 : meilleur sur longues sessions)
- **within_session_performance_slope** : évolution de la performance dans une même session (> 0 : amélioration progressive)
- **games_per_day_performance_slope** : impact du volume quotidien sur la performance
- **games_per_week_performance_slope** : impact du volume hebdomadaire sur la performance

Enfin, plusieurs métriques ont été établies pour évaluer la progression du joueur. Une seule a été retenue (cf section 4.C.) :

- **elo_gain** : gain total d'Elo (entre première et dernière partie)
- **elo_gain_per_game** : gain moyen par partie
- **elo_slope_per_game** : pente de progression en fonction des parties
- **elo_slope_per_day** : pente de progression en fonction du temps